Actividad 2. Clustering jerárquico

Se importa la base de datos de Amazon.

```
import scipy.cluster.hierarchy as shc
from sklearn.cluster import AgglomerativeClustering
from sklearn import decomposition
from scipy.spatial.distance import cdist
```

```
data = pd.read_excel("C:/Users/gus6e/OneDrive/Downloads/Amazon (1).xlsx")

data = data.rename(columns={data.columns[0]: "Cliente"})

columnas = list(data.columns[1:])

display(data.head())

print("Número de clientes:", len(data))
print("Variables de evaluación:", columnas)
```

	Cliente	Velocidad Entrega	Precio	Durabilidad	Imagen Producto	Valor Educativo	Servicio Retorno	Tamano Paquete	Calidad Producto	Numero Estrellas
0	Adam	205	3	345	235	24	23	26	21	17
1	Anna	9	15	315	33	25	4	42	215	28
2	Bernard	17	26	285	3	43	27	41	26	33
3	Edward	135	5	355	295	18	23	39	195	17
4	Emilia	3	45	48	39	34	46	225	34	43

```
Número de clientes: 100
Variables de evaluación: ['Velocidad Entrega', 'Precio', 'Durabilidad', 'Imagen Producto', 'Valor Educativo', 'Servicio Retorno', 'Tamano Paquete',
'Calidad Producto', 'Numero Estrellas']
```

Normalizamos los datos para poder tener todo en una escala comparable.

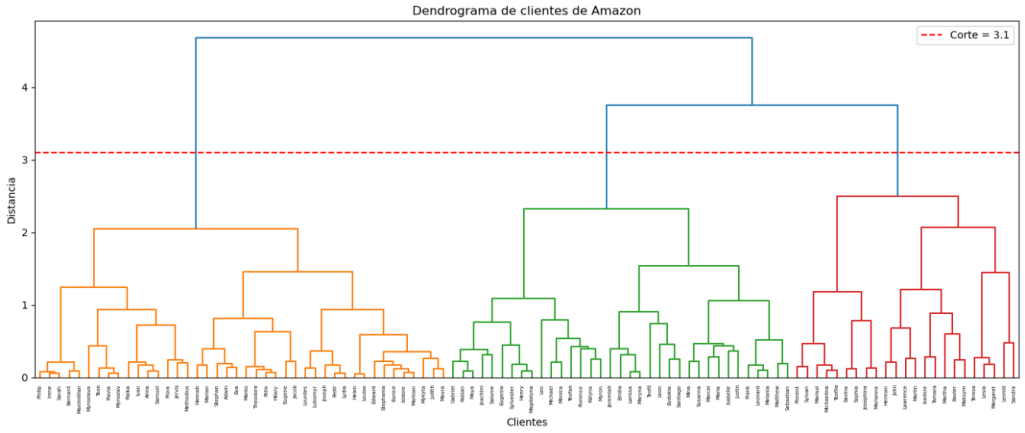
```
data_scaled = normalize(data[columnas].astype(float))

data_scaled = pd.DataFrame(
    data_scaled,
    columns=columnas,
    index=data["Cliente"]
)

display(data_scaled.head())
```

Cliente	Velocidad Entrega	Precio	Durabilidad	Imagen Producto	Valor Educativo	Servicio Retorno	Tamano Paquete	Calidad Producto	Numero Estrellas
Adam	0.438263	0.006414	0.737565	0.502399	0.051309	0.049171	0.055585	0.044895	0.036344
Anna	0.023235	0.038725	0.813234	0.085196	0.064542	0.010327	0.108431	0.555065	0.072287
Bernard	0.057235	0.087535	0.959520	0.010100	0.144770	0.090902	0.138036	0.087535	0.111102
Edward	0.258856	0.009587	0.680696	0.565649	0.034514	0.044101	0.074781	0.373904	0.032597
Emilia	0.011975	0.179625	0.191600	0.155675	0.135717	0.183617	0.898127	0.135717	0.171642

Conforme a lo que el código de clase visto en clase, usando método Ward y distancia euclidiana generamos nuestro dendograma.



En este caso, vemos que se asignan tres grupos o aglomeraciones principales, divididas en los tres colores que vistos en el dendograma, asimismo, formamos un data frame en el que asignamos a cada cliente a un aglomerado concreto, donde observamos en la parte de abajo que hay 23 clientes en el grupo 1, 42 para el grupo 2 y 35 para el grupo 3.

```
Colores del dendrograma:
{'C0', 'C1', 'C2', 'C3'}
Número de clústeres: 3
```

[6]:
```
cluster = AgglomerativeClustering(
    n_clusters=num_clusters_optimo,
    metric="euclidean",
    linkage="ward"
)

grupos = cluster.fit_predict(data_scaled)

dataframe = pd.DataFrame({
    "Cliente": data["Cliente"],
    "grupo": grupos + 1
})

dataframe2 = pd.concat(
    [data, dataframe[["grupo"]]],
    axis=1
)

display(dataframe2.head())

print("Cantidad de clientes por grupo:")
display(dataframe2.groupby("grupo").size())
```

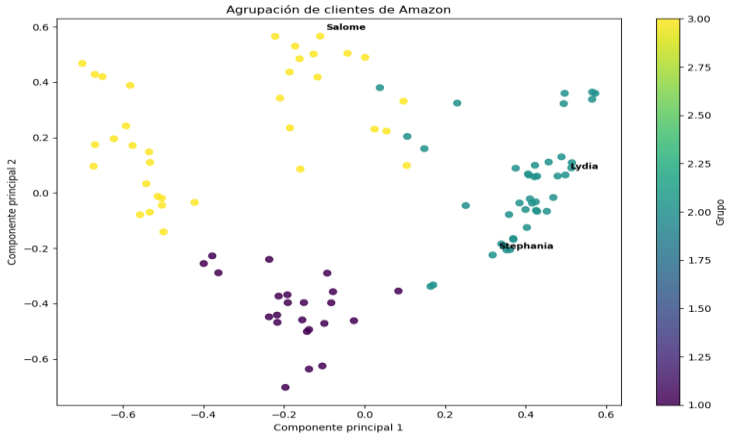
	Cliente	Velocidad Entrega	Precio	Durabilidad	Imagen Producto	Valor Educativo	Servicio Retorno	Tamano Paquete	Calidad Producto	Numero Estrellas	grupo
0	Adam	205	3	345	235	24	23	26	21	17	2
1	Anna	9	15	315	33	25	4	42	215	28	2
2	Bernard	17	26	285	3	43	27	41	26	33	2
3	Edward	135	5	355	295	18	23	39	195	17	2
4	Emilia	3	45	48	39	34	46	225	34	43	3

```
Cantidad de clientes por grupo:
grupo
1    23
2    42
3    35
dtype: int64
```

Conforme al análisis de componentes principales se realiza un diagrama de PCA en el que, a su vez, pedimos en el código el nombre de los clientes al que debemos de sugerir productos conforme a otros clientes, Salomé, Stephanía y Lydia, respectivamente.

```
plt.title("Agrupación de clientes de Amazon")

plt.colorbar(sc, label="Grupo")
plt.tight_layout()
plt.show()
```



Aquí vemos el mismo análisis pero hecho a modo de tabla, mediante el cual observamos lo que ya estaba descrito en el diagrama de PCA, vemos que Salomé pertenece al grupo 3, en cambio, Stephania y Lydia pertenecen al grupo 2, por lo que podríamos ver que las sugerencias para cada cliente van a ir conforme a las aglomeraciones encontradas en el método de aglomeraciones y análisis de componentes principales.



```
[9]: for nombre in clientes_objetivo:

         grupo_cliente = dataframe2.loc[
             dataframe2["Cliente"] == nombre, "grupo"
         ].iloc[0]

         clientes_mismo_grupo = dataframe2[
             (dataframe2["grupo"] == grupo_cliente) &
             (dataframe2["Cliente"] != nombre)
         ]

         print(f"\nCliente: {nombre}")
         print(f"Pertenece al grupo: {grupo_cliente}")
         print("Otros clientes del mismo grupo:")

         display(clientes_mismo_grupo[["Cliente", "grupo"]])
```

```
Cliente: Salome
Pertenece al grupo: 3
Otros clientes del mismo grupo:
```

	Cliente	grupo
4	Emilia	3
5	Fabian	3
7	Frank	3
9	Gabriel	3
11	Henry	3
13	Isabelle	3
17	Eugenia	3

Finalmente, hacemos las sugerencias finales a través de la función for, en la cual buscamos sondear para cada cliente objetivo un conjunto de clientes pertenecientes al mismo conglomerado cuya distancia sea menor.

```
for cliente, tabla in resultado.groupby(
    "Cliente objetivo", sort=False
):

    grupo = tabla["Grupo"].iloc[0]

    nombres = ", ".join(
        tabla["Cliente recomendado"].tolist()
    )

    print(f"\nRecomendaciones para {cliente}:")
    print(f"Pertenece al clúster {grupo}.")

    print(
        f"Recomendaría a {cliente} considerar los productos "
        f"que compraron {nombres}, debido a que sus perfiles "
        f"de evaluación son similares y pertenecen "
        f"al mismo clúster."
    )
```

```
Recomendaciones para Salomé:
Pertenece al clúster 3.
Recomendaría a Salomé considerar los productos que compraron Magdalyna, Fabian, Kalyna, debido a que sus perfiles de evaluación son similares y pertene
cen al mismo clúster.

Recomendaciones para Stephanía:
Pertenece al clúster 2.
Recomendaría a Stephanía considerar los productos que compraron Isidore, Markian, Judith, debido a que sus perfiles de evaluación son similares y perte
necen al mismo clúster.

Recomendaciones para Lydia:
Pertenece al clúster 2.
Recomendaría a Lydia considerar los productos que compraron Fedir, Joseph, Lourdes, debido a que sus perfiles de evaluación son similares y pertenecen
al mismo clúster.
```