Actividad 3: Inducción a la descomposición de valores singulares.

Una vez cargadas todas las librerías que se usan dentro de la lección de clase, cargamos la base de estudiantes utilizada en lecciones anteriores, de modo que obtenemos lo siguiente:

```
[3]: os.chdir("D:/gus6e/Documents")
estudiantes = pd.read_csv("EjemploEstudiantes.csv", sep=";", decimal=",", index_col=0)
print("Base original de estudiantes:")
display(estudiantes)
```

```
Base original de estudiantes:
```

	Matematicas	Ciencias	Espanol	Historia	EdFisica
Lucia	7.0	6.5	9.2	8.6	8.0
Pedro	7.5	9.4	7.3	7.0	7.0
Ines	7.6	9.2	8.0	8.0	7.5
Luis	5.0	6.5	6.5	7.0	9.0
Andres	6.0	6.0	7.8	8.9	7.3
Ana	7.8	9.6	7.7	8.0	6.5
Carlos	6.3	6.4	8.2	9.0	7.2
Jose	7.9	9.7	7.5	8.0	6.0
Sonia	6.0	6.0	6.5	5.5	8.7
Maria	6.8	7.2	8.7	9.0	7.0

Se calcularon los promedios de los 10 estudiantes y se clasificaron (de manera completamente arbitraria) en tres grupos: bajo, medio y alto para seguir el ejemplo de clasificación como en la lección usando los tipos de iris. Los resultados muestran que 7 estudiantes pertenecen al grupo medio, 2 al grupo bajo y solamente 1 al grupo alto. Inés obtuvo el promedio más alto (8.06), mientras que Sonia presentó el más bajo (6.54). En general, la mayoría de los estudiantes tienen un rendimiento académico medio. Esta clasificación nos servirá como referencia para observar si los estudiantes con promedios similares aparecen agrupados en las gráficas al aplicar SVD.

	Matematicas	Ciencias	Espanol	Historia	EdFisica	Promedio	Grupo
Lucia	7.0	6.5	9.2	8.6	8.0	7.86	Medio
Pedro	7.5	9.4	7.3	7.0	7.0	7.64	Medio
Ines	7.6	9.2	8.0	8.0	7.5	8.06	Alto
Luis	5.0	6.5	6.5	7.0	9.0	6.80	Bajo
Andres	6.0	6.0	7.8	8.9	7.3	7.20	Medio
Ana	7.8	9.6	7.7	8.0	6.5	7.92	Medio
Carlos	6.3	6.4	8.2	9.0	7.2	7.42	Medio
Jose	7.9	9.7	7.5	8.0	6.0	7.82	Medio
Sonia	6.0	6.0	6.5	5.5	8.7	6.54	Bajo
Maria	6.8	7.2	8.7	9.0	7.0	7.74	Medio

```
Cantidad por grupo:
Bajo    2
Medio   7
Alto    1
Name: count, dtype: int64
```

Se construyó la matriz A utilizando las calificaciones de los 10 estudiantes en las 5 materias. Cada fila representa a un estudiante y cada columna corresponde a una materia, por lo que se obtuvo una matriz de 10 × 5. Esta matriz contiene los datos que se utilizarán para aplicar la descomposición de valores singulares (SVD) y posteriormente representar a los estudiantes en dos y tres dimensiones para analizar sus posibles agrupaciones.

```
from numpy import array
from sklearn.decomposition import TruncatedSVD
A = estudiantes.to_numpy(dtype=float)
nombres = estudiantes.index.to_list()
materias = estudiantes.columns.to_list()
print("Matriz A: estudiantes (filas) x materias (columnas)")
print(A)
```

```
Matriz A: estudiantes (filas) x materias (columnas)
[[7.  6.5 9.2 8.6 8. ]
 [7.5 9.4 7.3 7.  7. ]
 [7.6 9.2 8.  8.  7.5]
 [5.  6.5 6.5 7.  9. ]
 [6.  6.  7.8 8.9 7.3]
 [7.8 9.6 7.7 8.  6.5]
 [6.3 6.4 8.2 9.  7.2]
 [7.9 9.7 7.5 8.  6. ]
 [6.  6.  6.5 5.5 8.7]
 [6.8 7.2 8.7 9.  7. ]]
```

Se aplicó el algoritmo SVD a la matriz de calificaciones, obteniendo las matrices U, Sigma y VT. En este caso, la matriz U contiene información sobre cómo se relacionan los estudiantes con las nuevas dimensiones generadas por SVD. Los valores obtenidos representan sus posiciones respecto a estas dimensiones. Estas matrices servirán para reducir los datos a dos y tres dimensiones y analizar posteriormente las agrupaciones de estudiantes, tal como PCA o los conglomerados vistos en la materia.

```
[ ]: U, s, VT = svd(A, full_matrices=True)
     Sigma = zeros((A.shape[0], A.shape[1]))
     Sigma[:len(s), :len(s)] = diag(s)
```

```
[ ]: print("Matriz U")
     print(U)
```

```
Matriz U
[[-3.30904778e-01 -2.98442471e-01  1.95957496e-01 -5.49129984e-01
   3.41498230e-01  3.14150349e-02 -1.23395489e-01  1.44668847e-01
  -3.94701586e-01 -3.89792548e-01]
 [-3.20798129e-01  3.55909651e-01 -2.40201517e-01 -6.92729616e-02
   2.04368756e-01 -4.82498850e-01  2.12566116e-01 -5.29979923e-01
  -2.91960519e-01  1.48477689e-01]
 [-3.38871518e-01  2.14752307e-01 -1.01355072e-01  1.12970083e-02
   1.76844101e-01 -1.27934010e-01 -3.25968835e-01 -5.72499990e-02
   7.00049221e-01 -4.25915443e-01]
 [-2.86319969e-01 -3.47796853e-01 -4.56775340e-01  6.26123724e-01
   3.29136285e-01  7.19838459e-02 -5.36517108e-04  2.16809671e-01
  -1.85075729e-01 -4.01432467e-02]
 [-3.03747698e-01 -3.04664300e-01  2.89885414e-01  2.58403657e-01
  -5.09400304e-01 -1.58301296e-01 -4.86485858e-01 -3.39970765e-01
  -1.65040306e-01  8.72429330e-03]]
```

La matriz Sigma muestra los valores singulares obtenidos mediante SVD. Se observa que el primer valor de 53.21 es mucho mayor que los demás, lo que indica que la primera dimensión concentra gran parte de la información de la matriz original. Los siguientes valores disminuyen considerablemente, por lo que tienen una menor contribución. Por otro lado, la matriz VT muestra cómo se relacionan las cinco materias con las nuevas dimensiones. Estos resultados nos permitirán identificar cuáles dimensiones son más importantes para reducir los datos y analizar las agrupaciones de estudiantes.

```
print("Matriz Sigma")
print(Sigma)
```

```
Matriz Sigma
[[53.21335049  0.          0.          0.          0.        ]
 [ 0.          5.35631448  0.          0.          0.        ]
 [ 0.          0.          3.80560674  0.          0.        ]
 [ 0.          0.          0.          1.46904724  0.        ]
 [ 0.          0.          0.          0.          0.47799818]
 [ 0.          0.          0.          0.          0.        ]
 [ 0.          0.          0.          0.          0.        ]
 [ 0.          0.          0.          0.          0.        ]
 [ 0.          0.          0.          0.          0.        ]
 [ 0.          0.          0.          0.          0.        ]]
```

```
print("Matriz VT")
print(VT)
```

```
Matriz VT
[[-0.40556463 -0.45759727 -0.46123811 -0.47103299 -0.43761787]
 [ 0.30388113  0.70497323 -0.20845983 -0.2165757  -0.56595801]
 [-0.00426062 -0.27229676  0.31573346  0.5963283  -0.6859601 ]
 [-0.56293162  0.34606734 -0.50555254  0.5444058   0.1066974 ]
 [-0.65288853  0.31576789  0.62332408 -0.28149203 -0.07909827]]
```

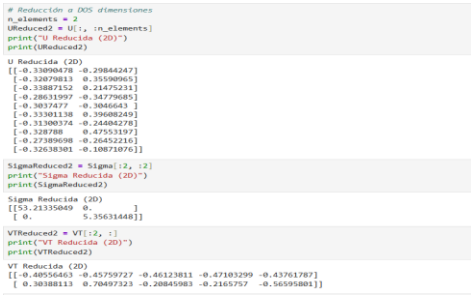
Primero se reconstruyó la matriz original utilizando las matrices obtenidas mediante SVD. Después, se seleccionaron las dos primeras columnas de la matriz U para representar a los 10 estudiantes en dos dimensiones. Con esta reducción se busca simplificar la información y facilitar la identificación de posibles agrupaciones entre estudiantes con características académicas similares.

```
B = U.dot(Sigma.dot(VT))
print("Reconstrucción de A:")
print(B)
```

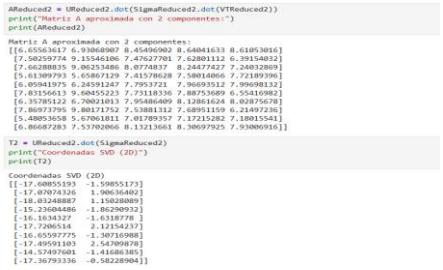
```
Reconstrucción de A:
[[7.  6.5 9.2 8.6 8. ]
 [7.5 9.4 7.3 7.  7. ]
 [7.6 9.2 8.  8.  7.5]
 [5.  6.5 6.5 7.  9. ]
 [6.  6.  7.8 8.9 7.3]
 [7.8 9.6 7.7 8.  6.5]
 [6.3 6.4 8.2 9.  7.2]
 [7.9 9.7 7.5 8.  6. ]
 [6.  6.  6.5 5.5 8.7]
 [6.8 7.2 8.7 9.  7. ]]
```

```
# Reducción a DOS dimensiones
n_elements = 2
UReduced2 = U[:, :n_elements]
print("U Reducida (2D)")
print(UReduced2)
```

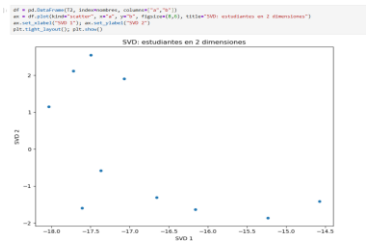
Se redujeron las matrices U, Sigma y VT utilizando únicamente las dos primeras dimensiones. La matriz U reducida contiene las coordenadas de los 10 estudiantes, mientras que Sigma conserva dos valores singulares (53.21 y 5.36). Por su parte, VT mantiene la información sobre cómo se relacionan las cinco materias con estas dimensiones. Esta reducción permitirá representar los datos de una manera más sencilla y analizar si existen agrupaciones entre los estudiantes.



Se reconstruyó una aproximación de la matriz original utilizando únicamente dos componentes de SVD. Los resultados muestran calificaciones estimadas que son cercanas a las originales, aunque presentan algunas diferencias debido a la reducción de dimensiones. También se obtuvieron las coordenadas de los 10 estudiantes en dos dimensiones, lo que permite representar sus características académicas de una manera más sencilla. Estas coordenadas sirven para elaborar la gráfica y observar qué estudiantes tienen perfiles de calificaciones similares y cuáles se encuentran más separados, como se mostrará en la imagen posterior.



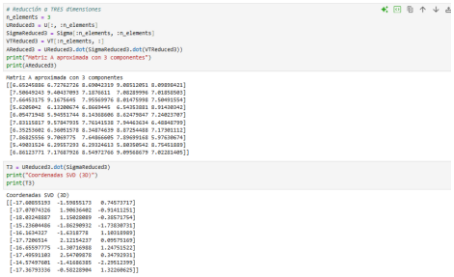
En la gráfica se observa cómo se distribuyen los 10 estudiantes utilizando las dos primeras dimensiones de SVD. Podemos identificar dos zonas principales: una en la parte superior, donde se encuentran cuatro estudiantes, y otra en la parte inferior, donde se encuentran los seis restantes. Esto indica que existen diferencias entre sus perfiles de calificaciones, aunque dentro de cada zona también hay cierta dispersión. Por lo tanto, la reducción a dos dimensiones permite visualizar posibles agrupaciones, pero todavía no se observa una separación completamente definida entre todos los estudiantes.



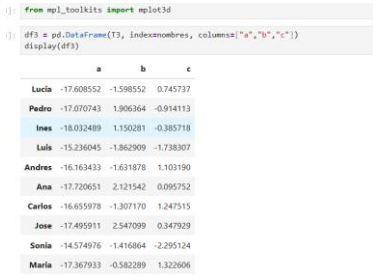
Al representar a los estudiantes con sus nombres y grupos, se observa una separación en dos zonas principales. En la parte superior se encuentran José, Ana, Pedro e Inés, mientras que en la parte inferior aparecen los otros seis estudiantes. Sin embargo, los colores muestran que estas agrupaciones no coinciden completamente con la clasificación por promedios, ya que los estudiantes del grupo medio aparecen en ambas zonas. También podemos observar que Luis y Sonia, pertenecientes al grupo bajo, se encuentran relativamente cerca, mientras que Inés, la única estudiante del grupo alto, aparece en la zona superior. Esto indica que SVD permite identificar similitudes en los perfiles de calificaciones, pero no necesariamente separa a los estudiantes según su promedio general. Cosa que vamos a comparar con SVD con 3 dimensiones.



Realizamos todos los pasos anteriores para 2 dimensiones para 3 dimensiones, tanto el cálculo de matrices reducidas para 3 componentes y encontramos nuevamente sus coordenadas, obteniendo tanto la matriz A como la de coordenadas.

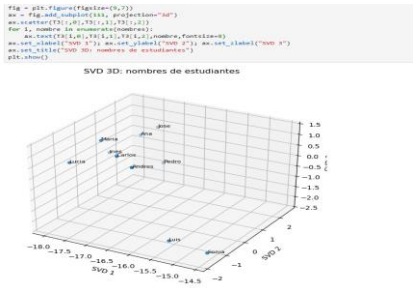


Se obtuvieron las coordenadas de los 10 estudiantes utilizando tres dimensiones de SVD. A diferencia de la reducción anterior, ahora cada estudiante tiene tres valores que representan su posición en el nuevo espacio. Las dos primeras dimensiones conservan las coordenadas utilizadas anteriormente, mientras que la tercera agrega información sobre las diferencias entre sus calificaciones. Esto permitirá observar con mayor detalle las similitudes y diferencias entre los estudiantes y analizar si sus agrupaciones se distinguen mejor que en dos dimensiones.

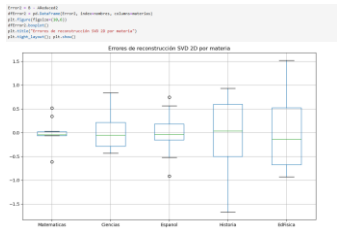


	a	b	c
Lucia	-17.608552	-1.598552	0.745737
Pedro	-17.070743	1.906364	-0.914113
Ines	-18.032489	1.150281	-0.385718
Luis	-15.236045	-1.862909	-1.738307
Andres	-16.163433	-1.631878	1.103190
Ana	-17.720651	2.121542	0.095752
Carlos	-16.655978	-1.307170	1.247515
Jose	-17.495911	2.547099	0.347929
Sonia	-14.574976	-1.416864	-2.295124
Maria	-17.367933	-0.582289	1.322606

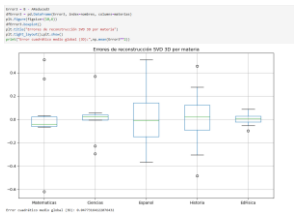
En la gráfica de tres dimensiones se observa con mayor detalle cómo se distribuyen los estudiantes según sus calificaciones. Luis y Sonia aparecen relativamente cercanos y separados de varios de sus compañeros, lo cual coincide con que ambos pertenecen al grupo de promedio bajo. Por otro lado, Ana, José, Pedro e Inés se encuentran en otra zona, aunque presentan diferencias entre sus posiciones. También se observa que Lucía, María, Carlos y Andrés tienen una distribución más dispersa. Al incorporar la tercera dimensión, podemos distinguir diferencias que no eran tan evidentes en la gráfica 2D, aunque todavía no se forman tres grupos completamente definidos.



En el diagrama de cajas se observan las diferencias entre las calificaciones originales y las estimadas mediante SVD con dos dimensiones. Matemáticas presenta los errores más concentrados alrededor de cero, lo que indica que sus calificaciones se reconstruyeron con mayor precisión (o que lo obtenido menos la estimación es más cercana a cero). Ciencias y Español muestran variaciones moderadas, mientras que Historia y Educación Física presentan una mayor dispersión de errores. Esto significa que, al reducir los datos a dos dimensiones, se conserva mejor la información de algunas materias que de otras. Error cuadrático de 0.3373.



Para tres dimensiones, se observa que los errores son menores en comparación con la reducción a dos dimensiones. Matemáticas, Ciencias y Educación Física presentan cajas relativamente pequeñas y cercanas a cero, aunque existen algunos valores atípicos. Por otro lado, Español e Historia muestran una mayor dispersión en sus errores. El error cuadrático medio global obtenido fue de 0.0477, lo que indica que las calificaciones reconstruidas son bastante cercanas a las originales. Esto demuestra que al utilizar tres dimensiones se conserva más información y se mejora la precisión de la reconstrucción.



Al comparar los resultados de SVD, observamos que con dos dimensiones se conserva el 99.41% de la energía de la matriz original, mientras que con tres dimensiones aumenta al 99.92%. Además, el error cuadrático medio disminuye de 0.3374 a 0.0477, lo que confirma que la reconstrucción con tres dimensiones es más precisa. Por otro lado, PCA conserva el 92.49% de la varianza con dos dimensiones y el 97.22% con tres.



```
# Comparación de la calidad de reconstrucción (SVD sin centrar)
energía = s**2 / np.sum(s**2)
print("Porcentaje de energía de los valores singulares:", np.round(100*energia,2))
print("Energía acumulada 2D:",round(100*sum(energia[:2]),2),"%")
print("Energía acumulada 3D:",round(100*sum(energia[:3]),2),"%")
print("ECM SVD 2D:",np.mean(Error2**2))
print("ECM SVD 3D:",np.mean(Error3**2))
```

```
Porcentaje de energía de los valores singulares: [9.842e+01 1.000e+00 5.000e-01 8.000e-02 1.000e-02]
Energía acumulada 2D: 99.41 %
Energía acumulada 3D: 99.92 %
ECM SVD 2D: 0.3373844951127626
ECM SVD 3D: 0.04773164122076432
```

Comparación con PCA

```
# PCA convencional centra las variables; por eso puede diferir del SVD aplicado a A sin centrar.
pca = PCA(n_components=3)
P = pca.fit_transform(estudiantes)
print("Varianza explicada PCA:",np.round(100*pca.explained_variance_ratio_,2))
print("Varianza acumulada PCA 2D:",round(100*sum(pca.explained_variance_ratio_[:2]),2),"%")
print("Varianza acumulada PCA 3D:",round(100*sum(pca.explained_variance_ratio_[:3]),2),"%")
```

```
Varianza explicada PCA: [61.14 31.35  4.73]
Varianza acumulada PCA 2D: 92.49 %
Varianza acumulada PCA 3D: 97.22 %
```

Conclusiones

Se puede observar cómo SVD es un muy buen método para reducir la cantidad de información con la que se trabaja sin perder tanta información, al igual que componentes principales, observando cómo matemáticamente llegamos a reproducir la información original a través de las matrices de una manera completamente certera, mismo que me puso a pensar en cuál era la métrica que fallaba para obtener las agrupaciones que buscamos, misma que vista en clase pudimos haber hecho con relaciones entre las mismas materias, tal como hacer divisiones conforme a materias de ciencias, kinestésicas o sociales, misma en la que podríamos hacer otro tipo de inferencias de mejor manera que coadyuvaran a agrupar de otro modo, por lo que se concluye que el método es muy útil, solo encontrar una agrupación adecuada para que esa información cobre un sentido de agrupación más claro, mismo que no pudo ser observado entre parámetros establecidos como promedios altos, medios y bajos.